P.E. DATA ENGINEER · CLOUD COMPUTING · CASO DE ESTUDIO

Andina Retail

El caso que acompaña todo el programa: una cadena de tiendas que necesita entender sus propios datos, del ticket de venta al reporte de gerencia. Este documento es la referencia completa para los laboratorios de las sesiones 2 a 6.

1 · La empresa

Andina Retail es una cadena de **40 tiendas** (Lima y provincias) de artículos de hogar y electro, con un canal **e-commerce** (web y app) que crece trimestre a trimestre. Trabaja con marca propia y productos importados, y el precio de esos importados depende del **tipo de cambio**.

Vende todo el año, pero su negocio vive de **campañas**: Navidad, Cyberdays y Día de la Madre concentran una parte desproporcionada de la venta. En esas semanas la operación se multiplica **3 a 5 veces**: más pedidos, más visitas, más facturas, más incidencias. Un sistema que funciona en marzo puede quedarse corto en diciembre, y un diseño que solo mira el día tranquilo no sirve.

Hoy las ventas de tienda viven en un servidor propio y el e-commerce en una base transaccional en la nube, construida en la sesión 2. El equipo (8 personas) conoce bien SQL, no ha operado una plataforma de datos, y la dirección ya pidió analítica y, más adelante, modelos de recomendación.

> **Objetivo de Andina:** poder responder preguntas de negocio con datos confiables y a tiempo, sin depender de que alguien abra cinco Excel a mano, y preparando el terreno para analítica avanzada e IA.

2 · Qué ya existe

En la sesión 2 se construyó la **base transaccional** del canal e-commerce: el sistema que registra cada venta tal como ocurre, con cinco entidades.

Entidad	Qué guarda	Claves y campos relevantes
Clientes	Quién compra	cliente_id; nombre, correo, ciudad, fecha de registro
Productos	Qué se vende	producto_id; nombre, categoría, precio unitario, activo
Pedidos	Cabecera de la compra	pedido_id; cliente, fecha, canal (web / app / tienda), estado
Líneas de pedido	Detalle y precio histórico	pedido + producto; cantidad, precio unitario de la venta
Pagos	Cómo y cuánto se pagó	pago_id; pedido, fecha/hora, método, monto

La muestra del laboratorio de la sesión 2 era mínima (5 clientes, 8 productos, 10 pedidos) para poder verificarla a simple vista. Este documento describe la **operación real de la empresa**: son los mismos datos, a escala. La escala de laboratorio de todo el programa está en la sección 7.

> **Regla del negocio:** el precio unitario se guarda en la línea del pedido, no en el producto. El precio del producto cambia con el tiempo; la factura debe conservar el precio del día de la venta. Esta regla ya está aplicada en la base y se mantiene en toda la plataforma.

3 · Las ocho fuentes de datos

Esta es la parte que la tarea del laboratorio necesita. Cada fuente indica qué es, formato, frecuencia, volumen, dueño y si trae datos personales. **PII** marca la presencia de datos personales (Ley 29733).

#	Fuente	Formato	Frecuencia	Volumen típico	PII
1	Base transaccional de pedidos y pagos	Relacional (tablas)	Transaccional	18.000 pedidos/día · pico 65.000	**Sí**
2	CSV del ERP: productos, clientes, ventas	CSV (3 archivos)	Diaria, 01:30	~500.000 filas/día en total	**Sí (clientes)**
3	Clics y navegación web/app	JSON (eventos)	Continua	2,5 M eventos/día · pico 12 M	**Sí (usuario, IP)**
4	Facturas electrónicas y contratos	PDF	Por evento	~6.000 facturas/día · 150 contratos/mes	**Sí (DNI/RUC)**
5	Logs de aplicación	Texto / JSON	Continua	8–12 M líneas/día (~2 GB)	**Posible (IP)**
6	Puntajes de modelos	CSV / JSON	Batch semanal	420.000 filas/semana	**Derivada**
7	Tipo de cambio USD/PEN	JSON (API)	Diaria, días hábiles	1 registro/día	No
8	Maestro de tiendas	CSV	Mensual o por cambio	40 filas	Menor

Fuente 1 · Base transaccional de pedidos y pagos

QUÉ ES	La base relacional del canal e-commerce (las cinco entidades de la sección 2). Es la **verdad exacta**: cada pedido, cada línea, cada pago.
VOLUMEN	**18.000 pedidos/día** en un mes tranquilo; hasta **65.000/día** en Cyberdays. Histórico de 24 meses: ~12 millones de pedidos, ~38 millones de líneas, ~13 millones de pagos, 420.000 clientes, 9.500 productos.
DUEÑO	Equipo de e-commerce.
PII	**Sí**: nombre, correo, teléfono y dirección del cliente.
CALIDAD	El 0,4 % de los pedidos queda en estado «pendiente» por falla de la pasarela de pago y nunca se concreta: hay que distinguirlos al analizar. Métodos de pago: tarjeta, Yape/Plin, transferencia.
DECISIÓN QUE DEPENDE DE ELLA	Toda métrica de venta exacta: facturación, conciliación con pagos, ticket promedio. No tolera estimaciones.

Fuente 2 · CSV del ERP: productos, clientes y ventas

QUÉ ES	Exportación nocturna que el back office descarga del ERP de tiendas. Tres archivos: catálogo de productos, maestro de clientes y detalle de ventas por tienda.
VOLUMEN	Productos: 9.500 filas (~1 MB). Clientes: 420.000 filas (~45 MB). Ventas: 40 tiendas × ~1.250 filas ≈ **50.000 filas/día** (~6 MB).
FRECUENCIA	Diaria a las 01:30; si el ERP se actualiza, puede atrasarse 1–2 horas sin avisar.
DUEÑO	Back office.
PII	**Sí**: el maestro de clientes trae correo, teléfono y ciudad de las tiendas físicas.
CALIDAD	El separador y la codificación varían entre sucursales (algunos archivos traen «;» y acentos rotos). ~2 % de correos vacíos o mal formados. Los mismos clientes aparecen con y sin documento de identidad: hay duplicados.
DECISIÓN QUE DEPENDE DE ELLA	Ventas de tienda física (que no pasa por la base del e-commerce) y catálogo unificado entre canal físico y digital.

Fuente 3 · Clics y navegación (web + app)

QUÉ ES	Eventos de comportamiento del canal digital: `page_view` `search` `add_to_cart` `checkout`. Cada evento trae sesión, usuario, página, timestamp y propiedades según el tipo.

VOLUMEN	**2,5 millones de eventos/día** normal; **10–12 millones/día** en campaña. ~35 GB/mes. 900.000 usuarios activos al mes.
FRECUENCIA	Continua: un evento cada pocos milisegundos en horas punta. Su valor decae rápido: para detectar abandono de carrito importa «ahora», no la semana pasada.
DUEÑO	Equipo de marketing digital.
PII	**Sí**: identificador de usuario y dirección IP. Para analítica basta el identificador seudonimizado.
CALIDAD	~1,5 % de eventos duplicados por reintentos de la app; sesiones cortadas por cambio de red; el esquema cambia cuando marketing agrega una propiedad nueva.
DECISIÓN QUE DEPENDE DE ELLA	Conversión de visita a compra y qué productos se comparan antes de decidir. Es la fuente que no cabe en la base transaccional.

Fuente 4 · Facturas electrónicas y contratos

QUÉ ES	Los comprobantes de pago electrónicos (facturas y boletas) y los contratos con proveedores y arrendamientos de locales.
VOLUMEN	**~6.000 facturas/día** (80–300 KB cada una); **~150 contratos/mes**. Son documentos: ni tablas ni columnas, texto y layout.
FRECUENCIA	Por evento: cada venta genera su documento al instante; los contratos entran cuando se firman.
DUEÑO	Contabilidad.
PII	**Sí**: DNI/RUC, nombre y dirección fiscal.
CALIDAD	~2 % de los documentos escaneados llegan ilegibles o rotados. El XML de SUNAT está estructurado, el PDF no.
DECISIÓN QUE DEPENDE DE ELLA	Auditoría y conciliación fiscal. Nadie consulta el PDF directo: se procesa, y lo que queda útil es el dato extraído.

Fuente 5 · Logs de aplicación

QUÉ ES	La bitácora técnica de la web, la app y el punto de venta en tienda: errores, latencias, reintentos, accesos.
VOLUMEN	**8–12 millones de líneas/día** (~2 GB), más en campaña por los fallos que aparecen bajo carga.
FRECUENCIA	Continua. Pasados 30 días ya no aporta: nadie depura un incidente de hace dos meses.
DUEÑO	Equipo de tecnología.
PII	**Posible**: en las excepciones a veces viajan IP o correo del usuario en la URL. Hay que revisar antes de dar acceso amplio.
CALIDAD	Semiestructurado: mezcla de texto plano y JSON; los stack traces rompen el formato de línea.
DECISIÓN QUE DEPENDE DE ELLA	Diagnóstico y auditoría técnica. No alimenta reportes de negocio; sí explica por qué un dato no llegó.

Fuente 6 · Puntajes de modelos

QUÉ ES	La salida del equipo de datos avanzados: probabilidad de compra por categoría y riesgo de abandono, calculados para cada cliente.
VOLUMEN	**420.000 filas/semana** (un puntaje por cliente activo). El histórico acumulado sirve para medir si los modelos mejoran.
FRECUENCIA	Batch, cada domingo en la madrugada. Ninguna decisión de negocio depende del segundo: la campaña de la semana se arma con el score del domingo.
DUEÑO	Equipo de datos avanzados.
PII	**Derivada**: el puntaje no es personal por sí solo, pero asociado al cliente sí. Quien reciba puntajes no debe recibir el dato crudo del cliente.
DECISIÓN QUE DEPENDE DE ELLA	A quién contactar en la próxima campaña y con qué oferta.

Fuente 7 · Tipo de cambio USD/PEN

QUÉ ES	La referencia diaria del dólar que usa la empresa para valorizar los productos importados. Se consulta de una API pública (publicación oficial del día hábil).
VOLUMEN	**1 registro/día** (dólar, compra, venta, fecha). Dos años de histórico son ~500 registros: la fuente más chica del caso.

FRECUENCIA	Diaria, días hábiles; se publica entre 08:00 y 09:00.
DUEÑO	Finanzas.
PII	No.
CALIDAD	Los feriados inesperados y las fallas del proveedor hacen que un día no llegue. El diseño debe sobrevivir a eso.
DECISIÓN QUE DEPENDE DE ELLA	Explicar por qué el margen de los importados se movió, aunque la venta no cambiara.

Fuente 8 · Maestro de tiendas

QUÉ ES	El catálogo de los 40 locales: código, ciudad, formato (flagship, regular, outlet), horario, gerente, fecha de apertura.
VOLUMEN	**40 filas** y ~15 columnas. Cambia poco: una apertura o un cambio de gerente al mes.
FRECUENCIA	Mensual o cuando cambia algo.
DUEÑO	Operaciones.
PII	Menor: nombre y correo corporativo del gerente.
DECISIÓN QUE DEPENDE DE ELLA	Es la dimensión que permite decir «la tienda de Trujillo vende más que la de Arequipa». Sin maestro, las ventas por tienda no se pueden explicar.

4 · Las preguntas que la plataforma debe responder

El diseño de Andina no se justifica por tecnología: se justifica por estas preguntas. Cada una depende de una o más fuentes de la sección 3.

1. **¿Cuánto vendimos?** Ventas por tienda, canal y día, comparables entre campañas y contra el año anterior. (Fuentes 1, 2, 8)
2. **¿Cuánto vale cada cliente?** Ticket promedio, frecuencia y canasta típica por formato de tienda. (Fuentes 1, 2, 8)
3. **¿Qué productos mueven el negocio?** Rotación por categoría y tienda; qué se compara y se abandona antes de comprar. (Fuentes 1, 3)
4. **¿Por qué la web no convierte?** Del evento de visita al pedido: dónde se cae la compra y qué campaña lo arregla. (Fuentes 1, 3)
5. **¿Los pagos cuadran?** Conciliación de pedidos contra pagos y contra facturación, con método y fecha. (Fuentes 1, 4)
6. **¿El dólar nos comió el margen?** Separar el efecto del tipo de cambio del efecto de la venta en productos importados. (Fuentes 1, 7)
7. **¿A quién le escribimos en la próxima campaña?** Segmentos con puntaje de compra y abandono, listos para contactar. (Fuentes 2, 6)
8. **¿Qué dato entró, cuándo y quién puede verlo?** Auditoría y trazabilidad de todo lo anterior. (Todas)

5 · Reglas y restricciones

- **Datos personales (Ley 29733):** las fuentes 1, 2, 3 y 4 traen PII. La plataforma debe permitir minimizar, seudonimizar y restringir acceso por rol. La analítica no necesita el nombre del cliente; sí necesita poder distinguir dos clientes distintos.
- **La venta no se toca:** el sistema transaccional sigue operando como está. La plataforma de datos lee de él; nunca escribe en él.
- **Campañas:** el diseño debe sostener picos de 3–5× sin rediseñarse. El costo de la plataforma sube cuando sube la frecuencia de ingesta y el cómputo: hay que saber qué cuesta cada decisión.

- **Equipo:** 8 personas que dominan SQL y conocen el negocio. Un diseño que exija administrar clústeres a mano las deja fuera del juego.
- **Cada zona responde una pregunta:** si dos zonas guardan lo mismo sin una razón, es duplicado, no arquitectura.

6 · Qué debe producir tu diseño

Con el caso anterior, tu diseño debe dejar decidido y **justificado** (no alcanza con nombrar servicios):

1. **Inventario de fuentes:** las 8 fuentes con formato, frecuencia, volumen, dueño y PII (la tabla de la sección 3 es la base; completa lo que falta).
2. **Ventana de ingesta:** para cada fuente, ¿se procesa por lotes o de forma continua? Justifica con la decisión de negocio que depende de ella, no con la moda del servicio.
3. **Zonas:** qué guarda la zona cruda (lo que llegó tal cual), la zona confiable (limpio, tipado, con calidad) y la zona de negocio (listo para responder las preguntas de la sección 4). Una pregunta distinta por zona.
4. **Formato y partición:** cómo llega cada dato y cómo se guarda; por qué se filtra como se filtra (fecha de negocio, tienda, canal…).
5. **Gobierno:** dónde van identidad y permisos, catálogo, linaje, cifrado, control de costo y minimización de PII.
6. **Riesgo:** una pregunta que todavía no puedes responder con estas fuentes, y un plan B si una fuente no llega (pista: ¿qué pasa si el tipo de cambio del día no se publica?).

7 · La escala del curso: real vs. laboratorio

Los volúmenes de este documento son los de la **operación real** de Andina, porque son los que hacen que las decisiones de diseño tengan sentido. En el curso no se aprovisiona ese volumen: los laboratorios trabajan con una **muestra proporcional** (aproximadamente 1 a 1.000) que cabe completa en una **suscripción gratuita** de Azure, sin agotar el crédito.

Fuente	Volumen real	Volumen de laboratorio
1 · Pedidos y pagos	18.000 pedidos/día · 12 M históricos · 420.000 clientes	~50 pedidos/día · ~1.500 en el mes · 500 clientes, 200 productos
2 · CSV del ERP	~500.000 filas/día	~250 filas/día (ventas: 40 tiendas × 1–2 filas)
3 · Clics y navegación	2,5 M eventos/día · pico 12 M	~5.000 eventos/día, mismo esquema, en archivos JSONL
4 · Facturas y contratos	~6.000 facturas/día · 150 contratos/mes	~20 facturas/día · 10 contratos en total
5 · Logs	8–12 M líneas/día · ~2 GB	~20.000 líneas/día · ~4 MB · retención de 7 días
6 · Puntajes de modelos	420.000 filas/semana	500 filas/semana (los clientes de la muestra)
7 · Tipo de cambio	1 registro/día	Igual: 1 registro/día
8 · Maestro de tiendas	40 filas	Igual: 40 filas

Tres reglas de la escala de laboratorio:

- **Las decisiones no cambian con la escala.** Mismas zonas, mismas ventanas, misma partición y misma rúbrica. Si tu diseño solo funciona porque los datos son pocos, no es un diseño: es una casualidad.
- **El streaming se simula con archivos que llegan por ventana.** La decisión de diseño es la misma (el dato decae rápido y entra continuo), pero no hay un servicio de ingesta pagando 24/7 en una cuenta de prueba.
- **El cómputo se usa y se apaga.** En una suscripción gratuita el presupuesto se agota por cómputo encendido de más, no por gigas guardados. Al cerrar cada sesión, el clúster se detiene.

Conexión con la tarea: este documento es el insumo del laboratorio «Diseñar el lakehouse de Andina» (sesión 3) y del resto del programa, donde el diseño se construye de verdad: la base transaccional ya existe (sesión 2), el lago se crea y se protege (sesión 4), el bronce recibe cómputo (sesión 5) y se convierte en plata lista para consultar (sesión 6). Las herramientas concretas las eligen tú en cada sesión; este caso define el problema, no la solución.